Infrastructure Attestation and Runtime Governance

Complementary Layers for AI System Trust

Executive synthesis

As AI systems become increasingly autonomous, distributed, and integrated into regulated environments, governance requirements are evolving beyond static evaluation and offline testing.

Two complementary governance layers are progressively emerging:

1. **Infrastructure attestation**
2. **Runtime behavioral instrumentation**

These layers address different but interconnected dimensions of AI system trust.

FR

Attestation d’Infrastructure et Gouvernance Runtime

Des couches complémentaires pour la confiance dans les systèmes d’IA

Synthèse exécutive

À mesure que les systèmes d'IA deviennent plus autonomes, distribués et intégrés dans des environnements régulés, les exigences de gouvernance dépassent progressivement les simples évaluations statiques et les tests hors ligne.

Deux couches complémentaires de gouvernance émergent progressivement :

1. **L'attestation d'infrastructure**
2. **L'instrumentation comportementale runtime**

Ces deux approches adressent des dimensions différentes mais complémentaires de la confiance appliquée aux systèmes d'IA.

---

1. Attestation d'infrastructure

« Le système fonctionne-t-il techniquement comme déclaré ? »

L'attestation d'infrastructure se concentre sur :

* l'intégrité du modèle,
* l'intégrité de la configuration,
* l'intégrité du déploiement,
* la vérification cryptographique,
* la conformité de l'environnement d'exécution,
* et les garanties de confiance au niveau système.

L'objectif est de produire des preuves vérifiables indiquant que :

* le modèle attendu est bien celui effectivement déployé,
* les règles annoncées sont réellement appliquées,
* les contraintes d'infrastructure restent intactes,
* et que la configuration du système n'a pas été modifiée silencieusement.

Cette couche fonctionne de manière comparable :

* à une attestation sécurisée d'infrastructure,
* à une vérification d'exécution de confiance,
* ou à une logique de "boîte noire" appliquée aux systèmes IA.

Les bénéfices typiques incluent :

* l'assurance réglementaire,
* l'auditabilité,
* la responsabilité du déployeur,
* la traçabilité infrastructurelle,
* et la vérification indépendante.

---

2. Instrumentation de gouvernance runtime

« Le comportement du système reste-t-il stable pendant l'exécution ? »

L'instrumentation de gouvernance runtime se concentre sur :

* la stabilité runtime,

* la continuité comportementale,

* les transitions de régime,

* les dérives opérationnelles,

* et l’observabilité pendant l’exécution.

L’objectif n’est pas de vérifier l’intégrité de l’infrastructure, mais d’observer si :

* le système reste comportementalement stable,

* les patterns runtime demeurent cohérents,

* et des signaux pertinents pour la gouvernance émergent pendant l’exécution.

Cette couche produit :

* des traces runtime,

* des signaux de stabilité,

* des classifications de régime,

* et des indicateurs d’intervention opérationnelle.

Les bénéfices typiques incluent :

* la supervision d’agents autonomes,

* l’oversight runtime,

* la réduction du risque opérationnel,

* le support à l’escalade humaine,

* et le monitoring orienté AI Act.

---

3. Des couches de gouvernance complémentaires

Ces approches ne doivent pas nécessairement être considérées comme concurrentes.

Elles répondent à des questions de gouvernance différentes :

Question de gouvernance	Couche concernée
« Le système déployé est-il authentique et conforme ? »	Attestation d’infrastructure
« Le comportement du système reste-t-il stable pendant l’exécution ? »	Instrumentation de gouvernance runtime

Une couche vérifie :

* l’intégrité du système.

L’autre observe :

* le comportement runtime.

Ensemble, elles peuvent contribuer :

* à une auditabilité renforcée,
* à des architectures de confiance multicouches,
* à des structures de preuve examinables indépendamment,
* et à une meilleure assurance de déploiement des systèmes IA.

---

4. Pertinence potentielle pour les environnements régulés

La combinaison :

* d’une attestation d’infrastructure examinable indépendamment,
* et d’une instrumentation comportementale runtime

pourrait devenir de plus en plus pertinente pour :

* les agents IA autonomes,
* les secteurs régulés,
* les workflows critiques,
* les contextes de conformité AI Act,
* le post-market monitoring,
* et les exigences de gouvernance opérationnelle.

En particulier en Europe, les cadres émergents de gouvernance imposent progressivement :

* la traçabilité,
* la supervision,
* le monitoring,
* et la responsabilité des déployeurs.

Des architectures de gouvernance multicouches pourraient donc devenir progressivement nécessaires.

---

5. Position méthodologique

Cette synthèse ne revendique pas :

* une sécurité IA complète,
* une prévention universelle des hallucinations,
* ni des garanties universelles de confiance.

L’objectif est simplement de clarifier comment :

* l’attestation d’infrastructure,
* et l’instrumentation comportementale runtime

peuvent fonctionner comme des couches complémentaires de gouvernance au sein des futures architectures IA.

EN

1. Infrastructure Attestation

“Is the system technically operating as declared?”

Infrastructure attestation focuses on:

* model integrity,
* configuration integrity,
* deployment integrity,
* cryptographic verification,
* execution environment compliance,
* and system-level trust guarantees.

The objective is to establish verifiable evidence that:

* the expected model is actually deployed,
* the declared rules are enforced,
* infrastructure constraints remain intact,
* and the system configuration has not been silently altered.

This layer operates similarly to:

* secure infrastructure attestation,
* trusted execution verification,
* or aircraft black-box governance.

Typical benefits include:

* regulatory assurance,
* auditability,
* deployer accountability,
* infrastructure traceability,
* and independent verification.

---

2. Runtime Governance Instrumentation

“Is the system behavior remaining stable during execution?”

Runtime governance instrumentation focuses on:

* runtime stability,
* behavioral continuity,
* regime transitions,
* operational drift,
* and execution-time observability.

The objective is not to verify infrastructure integrity, but to observe whether:

* the system remains behaviorally stable,
* runtime patterns remain coherent,
* and governance-relevant signals emerge during execution.

This layer produces:

* runtime evidence,
* stability signals,
* regime classifications,
* and operational intervention indicators.

Typical benefits include:

* autonomous agent supervision,
* runtime oversight,
* operational risk reduction,
* human escalation support,
* and AI Act-oriented monitoring.

---

3. Complementary Governance Layers

These approaches should not necessarily be viewed as competing systems.

They address different governance questions:

Governance Question	Governance Layer
“Is the deployed system authentic and compliant?”	Infrastructure attestation
“Is the system behavior remaining stable during execution?”	Runtime governance instrumentation

One layer verifies:

* system integrity.

The other observes:

* runtime behavior.

Together, they may support:

* stronger auditability,
* layered trust architectures,
* independently reviewable governance evidence,
* and more robust AI deployment assurance.

---

4. Potential Relevance for Regulated Environments

The combination of:

* independently reviewable infrastructure attestation,
* and runtime governance instrumentation

may become increasingly relevant for:

* autonomous AI agents,
* regulated sectors,
* critical workflows,
* AI Act compliance contexts,
* post-market monitoring,
* and operational governance requirements.

Particularly in Europe, emerging governance frameworks increasingly require:

* traceability,

* oversight,

* monitoring,

* and deployer accountability.

Layered governance architectures may therefore become progressively necessary.

---

5. Methodological Position

This synthesis does not claim:

* complete AI safety,

* universal hallucination prevention,

* or universal trust guarantees.

The objective is simply to clarify how:

* infrastructure attestation,

* and runtime behavioral instrumentation

may operate as complementary governance layers within future AI system architectures.

Part 1: What is ASRO?

ASRO (AI Systems Reliability Operator) is a **governance and technical attestation** technology for Artificial Intelligence.

Unlike traditional tools that analyze whether an AI response is "good" or "true," ASRO focuses on the **structural compliance** of the system. Here is specifically what it does:

* **Rule Verification (Attestation):** It checks in real-time if the AI is operating according to the rules and boundaries set for it (its "governance"). For example, if an operator claims the AI cannot access certain data, ASRO provides technical proof that this is indeed the case.

* **Independent Trust Layer:** It adds a layer of cryptographic proof between the AI operator and the user. This proves that the system configuration hasn't been secretly altered.

* **Technical Audit, Not Moral:** It does not judge the content (ethics, politeness, etc.), but rather creates an unfalsifiable record of the system's technical behavior. It is a tool for regulators, auditors, and legal teams.

The 3 Key Components:

1. **Host Meter Agent:** Installed on the server side (where the AI is running).

2. **Edge Meter Agent:** Installed on the user side (to verify what is received).

3. **ASRO Verifier:** An independent third party that reconciles both to confirm that the rules were respected.

In short: It’s like a **"black box" flight recorder for AI**: it doesn't record what the AI says, but how it is configured and whether it respects its technical contract at every moment.

Part 2: Comparison with NeoMundi.io

Comparing these two tools is highly relevant because they tackle the same problem—AI trust and reliability—but with **different technical philosophies**.

Summary: **ASRO** is a "black box" that monitors infrastructure and rules, while **NeoMundi** is a "thermometer" that measures the stability of the AI's reasoning.

1. Technical Approach (How they measure)

* **ASRO:** Focuses on **infrastructure attestation**. It verifies that the hardware and software components (GPUs, models, filters) are exactly what was promised. It’s a "systems" approach: it proves the plane's engine is running according to specifications.

* **NeoMundi:** Focuses on **inference stability**. It uses an algorithm (the "G-Score") to measure in real-time if the AI's response is stable or if it is "derailing" (hallucinating, drifting). It’s a "behavioral" approach: it measures if the pilot is lucid at the moment of making a decision.

2. Output Signal (What they tell you)

* **ASRO:** Provides **cryptographic proof** of compliance. It says: *"I technically certify that the AI being used is Model X, with Security Settings Y, and that nothing has been tampered with."*

* **NeoMundi:** Provides a **stability score (0 to 1)** and an action signal (ALLOW / FLAG / BLOCK). It says: *"This specific AI response is unstable (score 0.2); you should block this transaction or request human intervention."*

3. Integration

* **ASRO:** Requires installing agents ("Host Meter") at the core of the infrastructure where the AI runs. This is a deep, server-side integration.

* **NeoMundi:** Acts as a **lightweight API** (the "thermometer"). You send it the prompt and the response, and it returns an instant reliability score. No major infrastructure changes are needed.

4. Comparison Table

| Feature | **ASRO** | **NeoMundi** |

| --- | --- | --- |

| **Target Audience** | Regulators, Auditors, CTOs. | Developers, Ops, Compliance Officers (EU AI Act). |

| **Objective** | Prove the system has integrity. | Prevent a bad decision in real-time. |

| **Core Strength** | Unfalsifiable security and auditability. | Immediate detection of drift and hallucinations. |

| **Compliance** | Technical Governance & Attestation. | EU AI Act Articles 14/15 (Robustness & Oversight). |

Final Verdict

If you want to **prove to a client or regulator** that your AI infrastructure is secure and that you aren't cheating on the models being used, choose **ASRO**.

If you want to **deploy autonomous agents** (e.g., in finance or legal) and need an automatic "emergency stop" button the moment the AI starts talking nonsense, choose **NeoMundi**.

*** FR

---

explique moi en quelques mots ce que fait cette techno : https://aisystemsreliability.org/

ASRO (AI Systems Reliability Operator) est une technologie de gouvernance et d'attestation technique pour l'intelligence artificielle.

Contrairement aux outils classiques qui analysent si une réponse d'IA est "bonne" ou "vraie", ASRO se concentre sur la conformité structurelle du système. Voici ce qu'il fait concrètement :

Vérification des règles (Attestation) : Il vérifie en temps réel si l'IA fonctionne selon les règles et les limites qui lui ont été fixées (sa "gouvernance"). Par exemple, si l'opérateur prétend que l'IA ne peut pas accéder à certaines données, ASRO fournit une preuve technique que c'est bien le cas.

Couche de confiance indépendante : Il ajoute une couche de preuve cryptographique entre l'opérateur de l'IA et l'utilisateur. Cela permet de prouver que la configuration du système n'a pas été modifiée secrètement.

Audit technique, pas moral : Il ne juge pas le contenu (éthique, politesse, etc.), mais crée un enregistrement infalsifiable du comportement technique du système. C'est un outil pour les régulateurs, les auditeurs et les avocats.

Les 3 composants clés :

Host Meter Agent : Installé côté serveur (chez celui qui fait tourner l'IA).

Edge Meter Agent : Installé côté utilisateur (pour vérifier ce qui arrive).

ASRO Verifier : Un tiers indépendant qui réconcilie les deux pour confirmer que les règles ont été respectées.

En résumé, c'est comme une "boîte noire" d'avion pour l'IA : elle enregistre non pas ce que l'IA dit, mais la manière dont elle est paramétrée et si elle respecte son contrat technique à chaque instant.

et fais moi une comparaison avec neomundi.io

Il est très pertinent de comparer ces deux outils, car ils s'attaquent au même problème (la confiance et la fiabilité de l'IA) mais avec des philosophies techniques différentes.

En résumé : ASRO est une "boîte noire" qui surveille l'infrastructure et les règles, tandis que NeoMundi est un "thermomètre" qui mesure la stabilité du raisonnement de l'IA.

Voici le détail de leurs différences :

1. L'approche technique (Comment ils mesurent)

ASRO (aisystemsreliability.org) : Se concentre sur l'attestation de l'infrastructure. Il vérifie si les composants logiciels et matériels (GPU, modèles, filtres) sont ceux qui ont été promis. C'est une approche "système" : il prouve que le moteur de l'avion tourne selon les spécifications.

NeoMundi (neomundi.io) : Se concentre sur la stabilité de l'inférence. Il utilise un algorithme (le "G-Score") pour mesurer en temps réel si la réponse de l'IA est stable ou si elle est en train de "dérailler" (hallucination, dérive). C'est une approche "comportementale" : il mesure si le pilote est lucide au moment de prendre une décision.

2. Le signal produit (Ce qu'ils vous disent)

ASRO : Fournit une preuve cryptographique de conformité. Il vous dit : "Je certifie techniquement que l'IA utilisée est bien le modèle X, avec les paramètres de sécurité Y, et que rien n'a été modifié."

NeoMundi : Fournit un score de stabilité (0 à 1) et un signal d'action (ALLOW / FLAG / BLOCK). Il vous dit : "Cette réponse précise de l'IA est instable (score 0.2), vous devriez bloquer cette transaction ou demander une intervention humaine."

3. L'intégration

ASRO : Nécessite l'installation d'agents ("Host Meter") au cœur de l'infrastructure où tourne l'IA. C'est une intégration profonde côté serveur.

NeoMundi : Se présente comme une API légère (le "thermomètre"). On lui envoie la requête et la réponse, et il renvoie le score de fiabilité instantanément. Pas de changement d'infrastructure majeur.

4. Cas d'usage principaux

Caractéristique ASRO NeoMundi

Cible Régulateurs, Auditeurs, Direction technique. Développeurs, Ops, Responsables conformité (EU AI Act).

Objectif Prouver que le système est intègre. Empêcher une mauvaise décision en temps réel.

Point fort Sécurité et auditabilité infalsifiable. Détection immédiate des dérives et des hallucinations.

Conformité Gouvernance technique et "Technical Attestation". Articles 14/15 de l'EU AI Act (Robustesse et supervision).

Conclusion

Si vous voulez prouver à un client ou un régulateur que votre infrastructure IA est sécurisée et que vous ne trichez pas sur les modèles utilisés, choisissez ASRO.

Si vous voulez déployer des agents autonomes (ex: dans la finance ou le juridique) et que vous avez besoin d'un bouton "arrêt d'urgence" automatique dès que l'IA commence à dire n'importe quoi, choisissez NeoMundi.