Note de positionnement · Position note

Attestation d'infrastructure et gouvernance runtime

Infrastructure attestation and runtime governance

Couches complémentaires pour la confiance dans les systèmes d'IA

Complementary layers for AI system trust

Version 1.0 · Mai 2026

Version française

0. Synthèse exécutive

À mesure que les systèmes d'IA deviennent plus autonomes, distribués et intégrés dans des environnements régulés, les exigences de gouvernance dépassent progressivement les évaluations statiques et les tests hors ligne.

Deux couches complémentaires de gouvernance émergent progressivement :

1. L'attestation d'infrastructure.

2. L'instrumentation comportementale runtime.

Ces deux approches adressent des dimensions différentes mais complémentaires de la confiance appliquée aux systèmes d'IA. Le présent document précise leurs périmètres respectifs et leur articulation.

1. Attestation d'infrastructure

« Le système fonctionne-t-il techniquement comme déclaré ? »

L'attestation d'infrastructure se concentre sur l'intégrité du modèle, l'intégrité de la configuration, l'intégrité du déploiement, la vérification cryptographique, la conformité de l'environnement d'exécution et les garanties de confiance au niveau système.

L'objectif est de produire des preuves vérifiables indiquant que le modèle attendu est bien celui effectivement déployé, que les règles annoncées sont réellement appliquées, que les contraintes d'infrastructure restent intactes et que la configuration du système n'a pas été modifiée silencieusement.

Cette couche fonctionne de manière comparable à une attestation sécurisée d'infrastructure, à une vérification d'exécution de confiance, ou à une logique de boîte noire appliquée aux systèmes IA.

Bénéfices typiques : assurance réglementaire, auditabilité, responsabilité du déployeur, traçabilité infrastructurelle, vérification indépendante.

2. Instrumentation de gouvernance runtime

« Le comportement du système reste-t-il stable pendant l'exécution ? »

L'instrumentation de gouvernance runtime se concentre sur la stabilité runtime, la continuité comportementale, les transitions de régime, les dérives opérationnelles et l'observabilité pendant l'exécution.

L'objectif n'est pas de vérifier l'intégrité de l'infrastructure, mais d'observer si le système reste comportementalement stable, si les patterns runtime demeurent cohérents et si des signaux pertinents pour la gouvernance émergent pendant l'exécution.

Cette couche produit des traces runtime, des signaux de stabilité, des classifications de régime et des indicateurs d'intervention opérationnelle.

Bénéfices typiques : supervision d'agents autonomes, oversight runtime, réduction du risque opérationnel, support à l'escalade humaine, monitoring orienté AI Act.

3. Couches complémentaires

Ces approches ne doivent pas nécessairement être considérées comme concurrentes. Elles répondent à des questions de gouvernance différentes.

Question de gouvernance	Couche concernée
« Le système déployé est-il authentique et conforme ? »	Attestation d'infrastructure
« Le comportement du système reste-t-il stable pendant l'exécution ? »	Instrumentation de gouvernance runtime

Une couche vérifie l'intégrité du système. L'autre observe le comportement runtime. Ensemble, elles peuvent contribuer à une auditabilité renforcée, à des architectures de confiance multicouches, à des structures de preuve examinables indépendamment et à une meilleure assurance de déploiement des systèmes IA.

4. Pertinence pour les environnements régulés

La combinaison d'une attestation d'infrastructure examinable indépendamment et d'une instrumentation comportementale runtime pourrait devenir progressivement pertinente pour les agents IA autonomes, les secteurs régulés, les workflows critiques, les contextes de conformité AI Act, le post-market monitoring et les exigences de gouvernance opérationnelle.

En particulier en Europe, les cadres émergents de gouvernance imposent progressivement la traçabilité, la supervision, le monitoring et la responsabilité des déployeurs. Des architectures de gouvernance multicouches pourraient donc devenir progressivement nécessaires.

5. Position méthodologique

Cette synthèse ne revendique pas une sécurité IA complète, ni une prévention universelle des hallucinations, ni des garanties universelles de confiance.

L'objectif est de clarifier comment l'attestation d'infrastructure et l'instrumentation comportementale runtime peuvent fonctionner comme des couches complémentaires de gouvernance au sein des futures architectures IA.

6. Implémentations de référence

À titre illustratif, deux acteurs émergents incarnent chacune des deux couches.

Couche d'attestation d'infrastructure. ASRO (AI Systems Reliability Operator) opère une attestation cryptographique de la configuration, des modèles déployés et de l'intégrité du runtime. Approche serveur-side avec agents Host Meter et Edge Meter, et tiers vérificateur indépendant.

Couche d'instrumentation runtime. NeoMundi développe une mesure thermodynamique de la stabilité runtime, produisant un G-Score continu et une classification de régime (STABLE, SIGNAL, CRITICAL). Approche API légère, intégrable dans des orchestrateurs d'agents IA, sans modification profonde de l'infrastructure.

Les deux approches répondent à des questions distinctes et peuvent coexister, voire s'articuler, au sein d'une architecture de gouvernance multicouche.

English version

0. Executive synthesis

As AI systems become increasingly autonomous, distributed, and integrated into regulated environments, governance requirements are evolving beyond static evaluation and offline testing.

Two complementary governance layers are progressively emerging:

1. Infrastructure attestation.

2. Runtime behavioral instrumentation.

These layers address different but interconnected dimensions of AI system trust. The present document clarifies their respective scopes and articulation.

1. Infrastructure attestation

"Is the system technically operating as declared?"

Infrastructure attestation focuses on model integrity, configuration integrity, deployment integrity, cryptographic verification, execution environment compliance, and system-level trust guarantees.

The objective is to establish verifiable evidence that the expected model is actually deployed, that the declared rules are enforced, that infrastructure constraints remain intact, and that the system configuration has not been silently altered.

This layer operates similarly to secure infrastructure attestation, trusted execution verification, or black-box governance applied to AI systems.

Typical benefits: regulatory assurance, auditability, deployer accountability, infrastructure traceability, independent verification.

2. Runtime governance instrumentation

"Is the system behavior remaining stable during execution?"

Runtime governance instrumentation focuses on runtime stability, behavioral continuity, regime transitions, operational drift, and execution-time observability.

The objective is not to verify infrastructure integrity, but to observe whether the system remains behaviorally stable, whether runtime patterns remain coherent, and whether governance-relevant signals emerge during execution.

This layer produces runtime evidence, stability signals, regime classifications, and operational intervention indicators.

Typical benefits: autonomous agent supervision, runtime oversight, operational risk reduction, human escalation support, AI Act-oriented monitoring.

3. Complementary governance layers

These approaches should not necessarily be viewed as competing systems. They address different governance questions.

Governance question	Governance layer
"Is the deployed system authentic and compliant?"	Infrastructure attestation
"Is the system behavior remaining stable during execution?"	Runtime governance instrumentation

One layer verifies system integrity. The other observes runtime behavior. Together, they may support stronger auditability, layered trust architectures, independently reviewable governance evidence, and more robust AI deployment assurance.

4. Relevance for regulated environments

The combination of independently reviewable infrastructure attestation and runtime governance instrumentation may become increasingly relevant for autonomous AI agents, regulated sectors, critical workflows, AI Act compliance contexts, post-market monitoring, and operational governance requirements.

Particularly in Europe, emerging governance frameworks increasingly require traceability, oversight, monitoring, and deployer accountability. Layered governance architectures may therefore become progressively necessary.

5. Methodological position

This synthesis does not claim complete AI safety, universal hallucination prevention, or universal trust guarantees.

The objective is simply to clarify how infrastructure attestation and runtime behavioral instrumentation may operate as complementary governance layers within future AI system architectures.

6. Reference implementations

As an illustration, two emerging actors instantiate each of the two layers.

Infrastructure attestation layer. ASRO (AI Systems Reliability Operator) provides cryptographic attestation of configuration, deployed models, and runtime integrity. Server-side approach with Host Meter and Edge Meter agents, and an independent verifier.

Runtime instrumentation layer. NeoMundi develops a thermodynamic measurement of runtime stability, producing a continuous G-Score and a regime classification (STABLE, SIGNAL, CRITICAL). Lightweight API approach, integrable into AI agent orchestrators without deep infrastructure modification.

The two approaches answer distinct questions and can coexist, or be articulated together, within a multi-layer governance architecture.